

TP1 Transversal - EDA de Laptops en Amazon

AUTHOR

Alvaro Costa Millet y Mauricio Jurado

d. Importación y Descripción del Dataset

Cargamos las librerías necesarias e importamos el dataset procesado en Bash.

```
library(dplyr)
library(ggplot2)
library(tidyr)
library(readr)
library(knitr)

# Leemos el archivo y forzamos a que todas las columnas sean 100% numéricas
dataset <- read_csv("dataset.csv") %>%
  mutate(across(everything(), as.numeric))

glimpse(dataset)
```

Rows: 4,446

Columns: 7

```
$ screen_size <dbl> 14.00, 15.60, 15.66, 13.30, 15.30, 15.60, 13.30, 15.60, 16...
$ harddisk    <dbl> 1000, 1000, NA, 256, 256, 128, 256, 64, 512, 128, 512, 1, ...
$ ram         <dbl> 8, 64, 32, 8, 8, 8, 8, 4, 16, 8, 16, 16, 20, 16, 20, 16, 1...
$ graphics    <dbl> 0, 0, 1, 0, 0, 0, 0, 0, 1, 0, 1, 0, 0, 0, 0, 1, 0, 0, 1, 1...
$ cpu_speed   <dbl> 1.20, 1.46, 1.80, 1.46, 1.46, 1.46, 1.46, 1.46, 1.46, 1.46...
$ rating      <dbl> NA, 4.5, 5.0, 4.8, 4.8, 4.5, 4.7, 4.4, 4.4, 4.3, 4.4, 4.4,...
$ price       <dbl> 589.99, 999.99, 1599.00, 689.99, 1144.48, 299.99, 965.08, ...
```

1. Identificación de Variables Estadísticas

Tras el procesamiento de limpieza en la terminal, el dataset quedó estructurado así:

- **Variables Cuantitativas (Numéricas):** `screen_size`, `harddisk`, `ram`, `cpu_speed`, `rating` y `price`. Todas representan cantidades numéricas (continuas o discretas).
- **Variable Cualitativa (Categoría nominal):** `graphics`. Originalmente contenía texto, pero fue transformada en Bash a una codificación numérica (0 = Integrada, 1 = Dedicada).

2. Medidas de Posición por variable

Calculamos las medidas de tendencia central y de posición no central para todas las variables.

```
# Función auxiliar para calcular la Moda
calcular_moda <- function(x) {
  x <- na.omit(x)
  ux <- unique(x)
```

```
ux[which.max(tabulate(match(x, ux)))]
}

# 1. Media, Mediana y Moda (Tendencia Central)
medidas_centrales <- sapply(dataset, function(x) {
  c(Media = mean(x, na.rm=TRUE),
    Mediana = median(x, na.rm=TRUE),
    Moda = calcular_moda(x))
})
kable(t(medidas_centrales), digits = 2, caption = "Tendencia Central: Media, Mediana y Moda")
```

Tendencia Central: Media, Mediana y Moda

	Media	Mediana	Moda
screen_size	15.08	15.60	15.60
harddisk	719.11	512.00	1000.00
ram	26.38	16.00	16.00
graphics	0.37	0.00	0.00
cpu_speed	21.99	1.46	1.46
rating	11.69	4.50	5.00
price	1145.68	931.99	389.99

```
# 2. Cuartiles (25%, 50%, 75%)
cuartiles <- sapply(dataset, function(x) quantile(x, probs = c(0.25, 0.50, 0.75), na.rm=TRUE))
kable(t(cuartiles), digits = 2, caption = "Cuartiles")
```

Cuartiles

	25%	50%	75%
screen_size	14.00	15.60	15.60
harddisk	256.00	512.00	1000.00
ram	16.00	16.00	32.00
graphics	0.00	0.00	1.00
cpu_speed	1.46	1.46	1.46
rating	4.00	4.50	5.00
price	589.99	931.99	1599.00

```
# 3. Deciles (10% al 90%)
deciles <- sapply(dataset, function(x) quantile(x, probs = seq(0.1, 0.9, by=0.1), na.rm=TRUE))
kable(t(deciles), digits = 2, caption = "Deciles")
```

Deciles

	10%	20%	30%	40%	50%	60%	70%	80%	90%
screen_size	14.00	14.00	14.00	15.60	15.60	15.60	15.60	15.60	16.00
harddisk	2.00	128.00	256.00	512.00	512.00	1000.00	1000.00	1000.00	1152.00
ram	8.00	8.00	16.00	16.00	16.00	20.00	32.00	32.00	64.00
graphics	0.00	0.00	0.00	0.00	0.00	0.00	1.00	1.00	1.00
cpu_speed	1.10	1.46	1.46	1.46	1.46	1.46	1.46	1.46	1.80
rating	1.00	3.80	4.20	4.40	4.50	4.50	4.70	5.00	5.00
price	389.99	459.99	589.99	749.99	931.99	1047.11	1514.37	1699.00	2217.29

```
# 4. Percentiles destacados (1%, 5%, 95%, 99%)
percentiles <- sapply(dataset, function(x) quantile(x, probs = c(0.01, 0.05, 0.95, 0.99)))
kable(t(percentiles), digits = 2, caption = "Percentiles Destacados")
```

Percentiles Destacados


	1%	5%	95%	99%
screen_size	11.6	13.30	17.00	17.30
harddisk	1.0	1.00	2000.00	4000.00
ram	4.0	4.00	64.00	64.00
graphics	0.0	0.00	1.00	1.00
cpu_speed	1.1	1.10	2.40	5.19
rating	1.0	1.00	5.00	5.00
price	2.0	204.97	2807.51	4000.00

3. Histogramas y Diagramas de Caja

```
# Pasar a formato largo para graficar todo junto
dataset_long <- dataset %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Valor")


# Histogramas
ggplot(dataset_long, aes(x = Valor)) +
  geom_histogram(bins = 15, fill = "steelblue", color = "black") +
  facet_wrap(~Variable, scales = "free") +
  labs(title = "Histogramas por Variable", x = "Valor", y = "Frecuencia") +
  theme_minimal()
```

Histogramas por Variable



```
# Diagramas de Caja
ggplot(dataset_long, aes(y = Valor)) +
  geom_boxplot(fill = "lightgreen", color = "black") +
  facet_wrap(~Variable, scales = "free") +
  labs(title = "Boxplots por Variable", y = "Valor") +
  theme_minimal()
```

Boxplots por Variable



4. y 5. Interpretación y Frecuencias (Variable: price)

Tomamos la variable **price** para el análisis a profundidad.

```
# Calculamos el número exacto de intervalos con la fórmula de Sturges
num_intervalos <- nclass.Sturges(na.omit(dataset$price))

# Cortamos los datos en esa cantidad de intervalos
intervalos <- cut(dataset$price, breaks = num_intervalos, right = FALSE)

tabla_frecuencias <- dataset %>%
  mutate(Clase = intervalos) %>%
  filter(!is.na(Clase)) %>%
  group_by(Clase) %>%
  summarise(Frecuencia_Absoluta = n()) %>%
  mutate(
    Frecuencia_Relativa = Frecuencia_Absoluta / sum(Frecuencia_Absoluta),
    Frecuencia_Porcentual = Frecuencia_Relativa * 100,
    Frecuencia_Acumulada = cumsum(Frecuencia_Absoluta)
  )

kable(tabla_frecuencias, digits = 2, caption = "Tabla de Frecuencias Agrupadas - Precio")
```

Tabla de Frecuencias Agrupadas - Precio (USD)

Clase	Frecuencia_Absoluta	Frecuencia_Relativa	Frecuencia_Porcentual	Frecuencia_Acumulada
[-10.3,805)	1788	0.42	42.27	1788
[805,1.61e+03)	1435	0.34	33.92	3223
[1.61e+03,2.41e+03)	659	0.16	15.58	3882
[2.41e+03,3.22e+03)	227	0.05	5.37	4109
[3.22e+03,4.02e+03)	81	0.02	1.91	4190
[4.02e+03,4.83e+03)	19	0.00	0.45	4209
[4.83e+03,5.63e+03)	15	0.00	0.35	4224
[5.63e+03,6.44e+03)	3	0.00	0.07	4227
[7.24e+03,8.04e+03)	1	0.00	0.02	4228
[1.05e+04,1.13e+04)	2	0.00	0.05	4230

Interpretación del Histograma de Precios

- **Distribución en intervalos de clase:** Se agruparon los datos continuos del precio estableciendo límites inferiores y superiores dictados por la regla de Sturges.
- **Amplitud y marca de clase:** La amplitud es constante entre intervalos. La marca de clase (punto medio) representa a todos los datos de esa barra.
- **Construcción del gráfico:** Las barras adyacentes muestran en su área la frecuencia absoluta (cantidad de laptops) por rango de precio.

- **Análisis visual:** Análisis visual: Al observar el histograma de la variable price, se evidencia que la distribución de los datos no es simétrica. Presenta una clara asimetría positiva (sesgo hacia la derecha). Esto significa que la mayor concentración de datos está en los valores más bajos: la inmensa mayoría de las laptops cuestan entre 0 y 2.000 USD aproximadamente (donde se ubican las barras más altas). Hacia la derecha, la altura de las barras disminuye drásticamente, formando una “cola” que se extiende hacia valores muy altos (cerca de los 8.000 USD y más). Esta forma en la distribución nos indica la presencia de datos atípicos, correspondiendo a un grupo muy reducido de laptops con precios extremadamente caros en comparación con el resto del catálogo.